Trabalho Prático 1
Processamento Distribuído de Dados

Vinicius Trindade Dias Abel
Matrícula: 2020007112

Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte – MG – Brasil

viniciustda@ufmg.br

1. Estatísticas sobre a duração das músicas

Abordagem

Para esta tarefa, o objetivo foi analisar a distribuição da duração das músicas e remover valores atípicos (outliers).

A abordagem foi a seguinte:

1. O DataFrame de músicas **tracks_df** foi utilizado como base.
2. Inicialmente, foram calculadas as estatísticas descritivas (mínimo, média e máximo) da coluna **duration_ms** para obter uma visão geral dos dados.
3. Como método de pós-processamento, foi aplicada a Regra do Intervalo Interquartil (IQRR) para identificar e filtrar os outliers.
4. Os primeiro (Q1) e terceiro (Q3) quartis foram calculados utilizando a função **approxQuantile** do Spark, com uma margem de erro de **0.01** para garantir eficiência computacional.
5. Com base no IQR (Q3 − Q1), os limites inferior (Q1 − 1.5 × IQR) e superior (Q3 + 1.5 × IQR) foram definidos.
6. Um novo DataFrame foi criado utilizando a função **.filter()**, mantendo apenas as músicas com duração dentro desses limites.
7. Por fim, o número de outliers removidos foi contabilizado e as mesmas estatísticas descritivas foram recalculadas sobre o conjunto de dados filtrado.

Resultados

Tabela 1: Estatísticas Iniciais de Duração das Músicas

Duração Mínima (ms)	Duração Média (ms)	Duração Máxima (ms)
0	234.408,54976216817	10.435.467

Tabela 2: Estatísticas de Duração das Músicas (Sem Outliers)

Duração Mínima (ms)	Duração Média (ms)	Duração Máxima (ms)
107.866	226.795,8593433425	348.293

A análise inicial (Tabela 1) revela uma variação muito grande na duração das músicas. A presença de uma duração mínima de **0ms** sugere faixas sem conteúdo ou erros nos dados, enquanto a duração máxima de **10.435.467ms** (aproximadamente 174 minutos) indica a presença de outliers significativos, como mixes longos ou shows completos, que

distorcem a percepção de uma música típica. A aplicação da metodologia IQRR resultou na remoção de **570.909** faixas.

A Tabela 2 mostra o impacto da remoção dos outliers. A duração máxima foi reduzida para **348.293ms** (cerca de 5,8 minutos), um valor muito mais condizente com uma música padrão. A duração média também reduziu um pouco, ficando mais representativa. E a duração mínima não considera faixas sem conteúdo.

Portanto, o conjunto de dados filtrado oferece uma base mais confiável e realista para análises sobre a duração de músicas típicas na plataforma.

2. Artistas mais populares

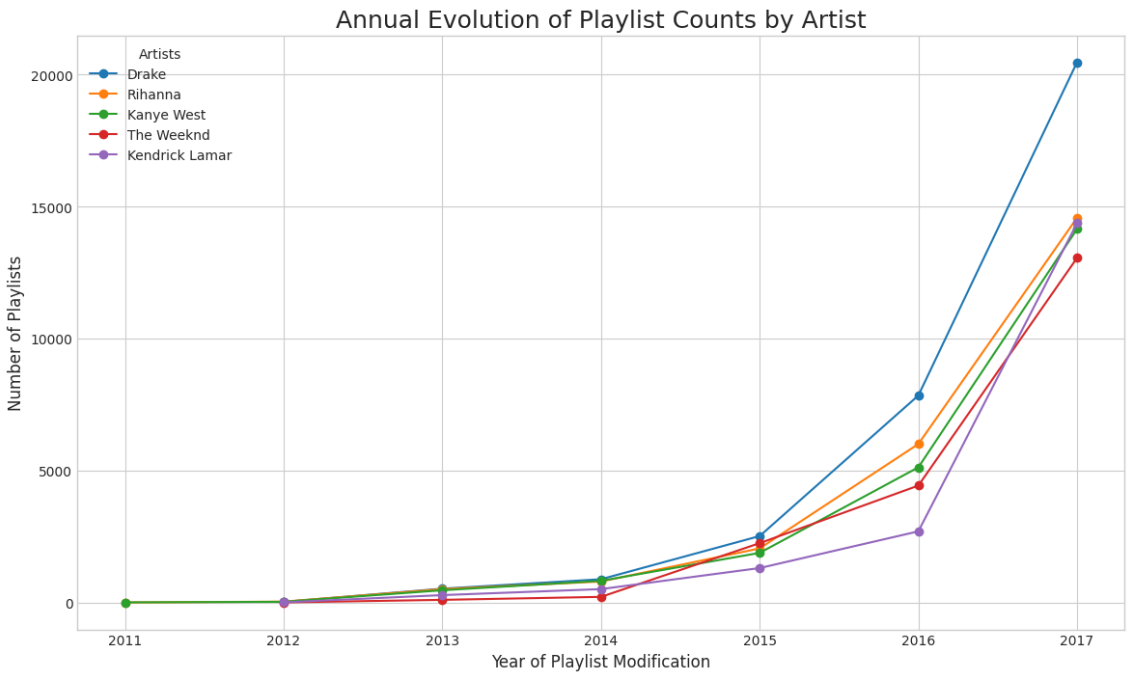
Abordagem

O objetivo desta tarefa foi identificar os cinco artistas mais populares e visualizar sua popularidade ao longo dos anos. A popularidade foi definida pelo número de playlists distintas em que um artista aparece.

A abordagem foi a seguinte:

1. Os DataFrames de músicas e playlists foram combinados (**.join()**) utilizando o ID da playlist (**pid**) como chave.
2. Para determinar os artistas mais populares, os dados foram agrupados por **artist_name**, e a contagem de **pids** distintos foi calculada para cada um. O resultado foi ordenado de forma decrescente e os 5 primeiros foram selecionados.
3. Em seguida, o DataFrame unido foi filtrado para conter apenas dados desses cinco artistas.
4. Uma nova coluna **year** foi extraída da coluna **modified_at** (timestamp UNIX) para permitir a agregação anual.
5. Os dados foram então agrupados por **year** e **artist_name**, e uma nova contagem de playlists distintas foi realizada para obter a popularidade anual de cada artista.
6. Para o resultado final, um **DataFrame Spark** de tamanho reduzido, foi convertido para um **DataFrame Pandas** e plotado com a biblioteca **matplotlib**, gerando um gráfico de linhas.

Resultados



O gráfico acima ilustra a evolução da popularidade dos cinco artistas mais presentes em playlists no dataset: Drake, Rihanna, Kanye West, The Weeknd e Kendrick Lamar. É notável um crescimento geral na presença de todos os artistas em playlists ao longo dos anos, o que indica a expansão da base de usuários do Spotify no período analisado (2010-2017). Drake demonstra uma liderança consistente e um crescimento acentuado, destacando-se como o artista mais popular na maior parte do período. Os outros artistas também demonstram crescimento na popularidade, e o número de playlists em que aparecem são semelhantes ao final do período analisado, mas não se aproximam dos resultados alcançados por Drake.

3. Comportamento das playlists

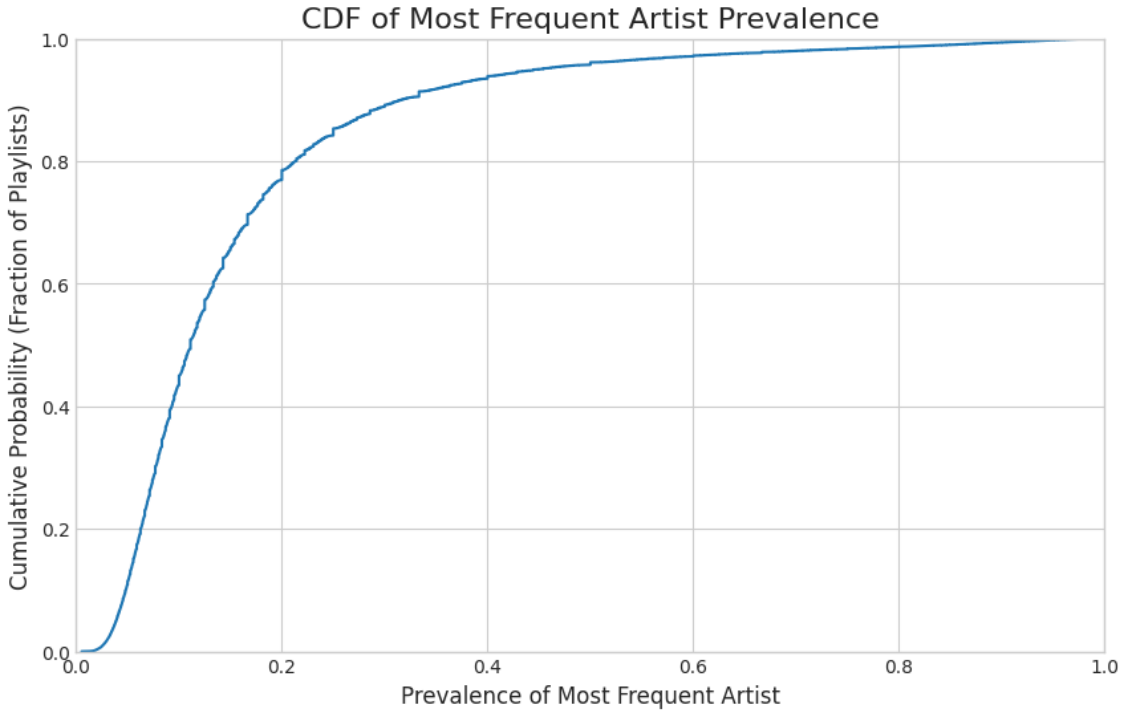
Abordagem

Esta tarefa buscou responder se as playlists do Spotify são, em geral, musicalmente diversas ou focadas em poucos artistas. Para isso, foi calculada a "prevalência" do artista mais frequente em cada playlist.

A abordagem foi a seguinte:

1. A partir do **tracks_df**, foram realizadas duas agregações iniciais: o número total de músicas por playlist e o número de músicas por artista dentro de cada playlist.
2. A partir da segunda agregação, foi calculada a contagem máxima de músicas de um único artista para cada playlist.
3. Esses dois resultados foram unidos pelo ID da playlist, permitindo o cálculo da prevalência, definida como a fração da contagem do artista mais frequente pelo total de músicas na playlist.
4. Todos os valores de prevalência foram coletados do **DataFrame Spark** para uma lista em Python.
5. Utilizando as bibliotecas **numpy** e **matplotlib**, os dados foram ordenados e plotados como uma Função de Distribuição Cumulativa (CDF), que visualiza a distribuição de probabilidade dos valores de prevalência.

Resultados



O gráfico da Função de Distribuição Cumulativa (CDF) acima responde à pergunta central da tarefa. A forma da curva, que sobe acentuadamente no lado esquerdo, indica que a grande maioria das playlists possui um baixo valor de prevalência do artista mais frequente. Analisando o gráfico, é possível observar que aproximadamente 80% das playlists (eixo Y em 0.8) apresentam uma prevalência de 0.2 ou menos (eixo X em 0.2). Isso significa que, em 80% dos casos, o artista mais popular em uma playlist é responsável por, no máximo, 20% de suas músicas. Este resultado demonstra que o comportamento predominante dos usuários ao criar playlists é o de agregar músicas de uma grande variedade de artistas, favorecendo a diversidade musical, e não reunir músicas apenas de um mesmo artista.