

Trabalho Prático 2

Algoritmos de Aprendizado de Máquina

Vinicius Trindade Dias Abel
Matrícula: 2020007112

Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte – MG – Brasil

viniciustda@ufmg.br

1. Aprendizado supervisionado - Regressão

1) Compare quais dos modelos a seguir apresenta melhor performance. Escolha uma métrica (MAE o MSE e o RMSE) e justifique por que ela é mais interessante para o problema abordado:

- a) Regressão Linear
- b) Random Forest
- c) Support Vector Regression (SVR)
- d) Escolha um modelo regressivo do seu interesse.

Resultado:

Modelo: Regressão Linear

RMSE: 4.1957

Modelo: Random Forest

RMSE: 3.7932

Modelo: SVR

RMSE: 4.3201

Modelo: Gradient Boosting

RMSE: 3.9093

O melhor modelo foi o 'Random Forest' com um RMSE de 3.7932

Análise:

Métrica utilizada

A métrica escolhida para avaliar a performance dos modelos foi o **RMSE (Root Mean Squared Error - Raiz do Erro Quadrático Médio)**, por conta das suas características principais:

1. **Interpretabilidade:** O RMSE é expresso na mesma unidade da variável alvo. Isso significa que um erro de pontos no RMSE é diretamente interpretável como o erro médio do modelo na escala da variável alvo.
2. **Penalização de Erros Grandes:** Ao elevar os erros ao quadrado antes de calcular a média, o RMSE penaliza erros grandes de forma muito mais significativa do que erros pequenos. Como estamos trabalhando com avaliação

de desempenho de alunos, essa propriedade é interessante, pois um modelo que comete erros grandes é consideravelmente pior do que um que comete vários erros pequenos.

Comparação de Performance

Os quatro modelos propostos foram treinados e avaliados no mesmo conjunto de dados, e seus desempenhos foram medidos pelo RMSE. Os resultados obtidos foram:

- **Regressão Linear:** RMSE = 4.1957
- **Random Forest:** RMSE = 3.7932
- **SVR:** RMSE = 4.3201
- **Gradient Boosting:** RMSE = 3.9093

Com base nesses resultados, o modelo que apresentou a melhor performance, ou seja, o menor erro de previsão, foi o **Random Forest**, com um RMSE de **3.7932**.

2) Quais são as variáveis (features) mais importantes de acordo com a Regressão Linear e com Random Forest? Qual a diferença de interpretação das variáveis em cada modelo?

Resultado:

--- 15 Variáveis Mais Importantes (Random Forest) ---

	Feature	Importancia
55	remainder__absences	0.189750
48	remainder__failures	0.141214
51	remainder__goout	0.047325
43	remainder__age	0.043389
54	remainder__health	0.043162
47	remainder__studytime	0.031355
50	remainder__freetime	0.029782
53	remainder__Walc	0.028893
44	remainder__Medu	0.028391
45	remainder__Fedu	0.028190
46	remainder__traveltime	0.026933
49	remainder__famrel	0.024527
26	cat__guardian_other	0.018022
13	cat__Mjob_services	0.015940
10	cat__Mjob_at_home	0.014231

--- 15 Variáveis Mais Importantes (Regressão Linear) ---

	Feature	Coeficiente	Importancia_Absoluta
48	remainder__failures	-1.854106	1.854106
14	cat__Mjob_teacher	-1.192463	1.192463
11	cat__Mjob_health	1.038329	1.038329
19	cat__Fjob_teacher	0.891945	0.891945
37	cat__higher_no	-0.875440	0.875440
38	cat__higher_yes	0.875440	0.875440
47	remainder__studytime	0.757643	0.757643
2	cat__sex_F	-0.747955	0.747955
3	cat__sex_M	0.747955	0.747955
30	cat__famsup_yes	-0.628216	0.628216
29	cat__famsup_no	0.628216	0.628216
13	cat__Mjob_services	0.589838	0.589838
26	cat__guardian_other	0.564322	0.564322
41	cat__romantic_no	0.508083	0.508083
42	cat__romantic_yes	-0.508083	0.508083

Análise:

Análise de Importância das Variáveis

A análise de importância de variáveis foi realizada para os modelos Random Forest e Regressão Linear, revelando quais características dos alunos mais influenciaram as previsões de cada um.

Variáveis Mais Importantes - Random Forest

O Random Forest mede a importância de uma variável pela sua capacidade de reduzir a impureza (erro) do modelo ao tomar decisões. As 5 features mais importantes foram:

1. **Número de faltas** (remainder__absences)
2. **Número de reprovações anteriores** (remainder__failures)
3. **Frequência de saídas com amigos** (remainder__goout)
4. **Idade do aluno** (remainder__age)
5. **Estado de saúde atual** (remainder__health)

Variáveis Mais Importantes - Regressão Linear

A Regressão Linear mede a importância pelo valor absoluto de seus coeficientes, que indicam o peso da relação linear de cada variável com a nota final. As 5 mais importantes foram:

1. **Número de reprovações anteriores** (remainder__failures)
2. **Trabalho da mãe ser "professora"** (cat__Mjob_teacher)
3. **Trabalho da mãe na área da "saúde"** (cat__Mjob_health)
4. **Trabalho do pai ser "professor"** (cat__Fjob_teacher)
5. **Não querer cursar ensino superior** (cat__higher_no)

Diferença na Interpretação


A principal diferença entre as duas abordagens é como a "importância" é definida:

- **Random Forest (feature_importances_)**: Mede o **poder preditivo geral** de uma feature. Uma variável com alta importância foi fundamental para o modelo fazer previsões mais corretas, sendo capaz de capturar relações complexas e não-lineares.
- **Regressão Linear (coef_)**: Mede o **peso e a direção de uma relação estritamente linear**. O valor absoluto do coeficiente indica a magnitude do impacto (quanto a nota muda para cada unidade da feature), e o sinal (+ ou -) indica se essa relação é positiva ou negativa.

Em resumo, o Random Forest nos diz quais variáveis são mais **úteis** para prever, enquanto a Regressão Linear nos diz quais variáveis têm **influência linear** mais forte no resultado.

3) Qual o impacto na performance do modelo de remover as features menos relevantes (de acordo com cada modelo)?

Resultado – Regressão Linear:



O melhor resultado absoluto foi um RMSE de 4.1380 usando as 22 features mais importantes.

Definindo uma tolerância de 1.0%, o limite de RMSE aceitável é: 4.1794

O modelo mais simples que atinge essa performance é o com 22 features, obtendo um RMSE de 4.1380.

--- Comparação Final: Original vs. Ponto Ideal ---

RMSE do modelo original (56 features) : 4.1957

RMSE do modelo no ponto ideal (22 features): 4.1380

Diferença: +0.0576

Resultado: Houve uma pequena e aceitável perda de performance em troca de um modelo mais simples.

Análise – Regressão Linear:

Impacto da Remoção de Features Menos Relevantes na Regressão Linear

A remoção de features menos relevantes teve um **impacto positivo e significativo** na performance do modelo de Regressão Linear. A análise demonstrou que um modelo mais simples, utilizando um subconjunto das variáveis mais importantes, não apenas se tornou mais eficiente, como também obteve uma **maior precisão preditiva**.

Metodologia e Análise

Para avaliar o impacto, foi realizada uma análise iterativa, treinando e avaliando o modelo com um número crescente de features. A ordem de importância das features foi determinada pelos coeficientes do próprio modelo de Regressão Linear. Os resultados-chave foram:

- **Performance Original (com 56 features):** RMSE = 4.1957
- **Melhor Performance Identificada:** Com apenas **22 features**, o modelo atingiu seu melhor RMSE = 4.1380.


Conclusão

O impacto de remover as 34 features menos relevantes, de acordo com o critério da Regressão Linear, foi benéfico por duas razões principais:

1. **Melhora na Performance:** O erro do modelo (RMSE) diminuiu de 4.1957 para 4.1380. Isso indica que as features removidas não estavam contribuindo positivamente para as previsões, possivelmente por introduzirem ruído, o que pode piorar a performance de modelos lineares.
2. **Redução de Complexidade:** O modelo final se tornou mais simples e eficiente, utilizando menos da metade das features originais para obter um resultado superior.

Portanto, a seleção de features se mostrou uma etapa valiosa, melhorando a capacidade de generalização do modelo de Regressão Linear.

Resultado – Random Forest:



O melhor resultado absoluto foi um RMSE de 3.7625 usando as 51 features mais importantes.

Definindo uma tolerância de 1.0%, o limite de RMSE aceitável é: 3.8001

O modelo mais simples que atinge essa performance é o com 42 features, obtendo um RMSE de 3.7901.

--- Comparação Final: Original vs. Ponto Ideal ---

RMSE do modelo original (56 features) : 3.7932

RMSE do modelo no ponto ideal (42 features): 3.7901

Diferença: +0.0030

Resultado: A performance se manteve praticamente a mesma, mas com um modelo mais simples.

Análise – Random Forest:

Impacto da Remoção de Features Menos Relevantes no Random Forest

A remoção de features menos relevantes teve um **impacto positivo** na redução de complexidade do modelo Random Forest, mantendo uma performance quase idêntica. A análise demonstrou que um modelo mais simples, utilizando um subconjunto das variáveis mais importantes, é tão eficaz quanto o modelo completo.

Metodologia e Análise

Para avaliar o impacto, foi realizada uma análise iterativa que treinou e avaliou o modelo com um número crescente de features, da mais importante à menos importante. Os resultados-chave foram:

- **Performance Original (com 56 features):** RMSE = 3.7932
- **"Ponto de Equilíbrio" Identificado:** Com apenas **42 features**, o modelo atingiu um RMSE = 3.7901.

Conclusão

O impacto de remover as 14 features menos relevantes pode ser avaliado em dois pontos:

1. **Melhora na Performance:** O erro do modelo (RMSE) diminuiu de 3.7932 para 3.7901. Isso indica que as 14 features removidas contribuíam muito pouco para o poder preditivo do modelo, já que a diferença no RMSE foi mínima.
2. **Redução de Complexidade:** O modelo final se tornou mais simples e eficiente, utilizando 25% menos features para alcançar uma performance equivalente ao original.

Portanto, a seleção de features é uma prática vantajosa, pois permite a criação de um modelo mais simples sem sacrificar a precisão.

4) Avalie o impacto da normalização dos dados nas métricas (no SkLearn, StandardScaler e MinMaxScaler). A forma de normalização muda significativamente os resultados? Se sim, por quê?

Resultado:

--- Rodando modelos com: Sem Normalização ---

Regressão Linear: RMSE = 4.1957

Random Forest: RMSE = 3.7932

SVR: RMSE = 4.3201

Gradient Boosting: RMSE = 3.9093

--- Rodando modelos com: Com StandardScaler ---

Regressão Linear: RMSE = 4.1957

Random Forest: RMSE = 3.7610

SVR: RMSE = 4.1075

Gradient Boosting: RMSE = 3.9105

--- Rodando modelos com: Com MinMaxScaler ---

Regressão Linear: RMSE = 4.1957

Random Forest: RMSE = 3.7771

SVR: RMSE = 4.2714

Gradient Boosting: RMSE = 3.9191

--- Tabela Comparativa de Performance (RMSE) ---

	Sem Normalização	Com StandardScaler	Com MinMaxScaler
Modelo			
Regressão Linear	4.195681	4.195681	4.195681
Random Forest	3.793169	3.760959	3.777114
SVR	4.320126	4.107479	4.271370
Gradient Boosting	3.909271	3.910495	3.919053

Análise:

Avaliação do Impacto da Normalização

A análise dos resultados mostra que o impacto da normalização dos dados na performance dos modelos **depende fundamentalmente da natureza do algoritmo** utilizado.

Impacto nos Modelos Sensíveis à Escala (SVR e Regressão Linear)

- **SVR (Support Vector Regression):** Foi o modelo **mais impactado positivamente**. Seu erro (RMSE) diminuiu de **4.32** (sem normalização) para **4.10** ao usar o StandardScaler. Isso ocorre porque o SVR é um algoritmo baseado em distância, e a normalização garante que features com escalas muito diferentes contribuam de forma equilibrada para o modelo.
- **Regressão Linear:** Curiosamente, não apresentou **nenhuma alteração** na performance. A implementação padrão do LinearRegression no Scikit-learn utiliza uma solução matemática que se ajusta automaticamente à escala das features, tornando-a insensível a esta etapa de pré-processamento para a métrica de erro final.

Impacto nos Modelos Baseados em Árvores (Random Forest e Gradient Boosting)


- Ambos os modelos, **Random Forest** e **Gradient Boosting**, quase não sofreram alterações com a normalização. Seus valores de RMSE permaneceram semelhantes em todos os três cenários. Isso acontece porque algoritmos baseados em árvores de decisão fazem divisões nos dados baseadas em "pontos de corte" e não na magnitude absoluta dos valores, o que os tornam naturalmente robustos à escala das features.

Conclusão

Sim, a normalização muda significativamente os resultados, mas **apenas para modelos cuja matemática é sensível à escala dos dados**, como o SVR. Para este, o StandardScaler foi a técnica mais eficaz. Para os modelos baseados em árvores, a normalização não é uma etapa necessária.

5) Realize uma análise de erro para os modelos treinados. Para cada modelo (Linear, Random Forest e SVR), plote os resíduos (erro entre valor real e predito). Qual modelo apresenta menor viés e menor variância nos resíduos?

Resultado:



--- Tabela para Análise Quantitativa ---

	Média dos Erros (Viés)	Desvio Padrão dos Erros (Variância)
Modelo		
Regressão Linear	0.238348	4.188905
Random Forest	-0.230886	3.753866
SVR	-0.188526	4.103150

Análise:

Análise de Erro dos Modelos

A análise de erros, que é a diferença entre os valores reais e os previstos, foi realizada para avaliar a qualidade e o comportamento dos erros de cada modelo. A análise combinou uma avaliação visual dos gráficos com as métricas quantitativas da tabela.

Análise Visual

Os gráficos de erros plotam os erros de cada previsão. O ideal é uma nuvem de pontos aleatória e uniforme em torno da linha horizontal em $y=0$.

- O gráfico do **Random Forest** é o que mais se aproxima deste ideal. Ele mostra uma nuvem de pontos compacta e sem padrões claros, sugerindo um bom ajuste.
- Os gráficos da **Regressão Linear** e do **SVR**, por outro lado, mostram nuvens de pontos mais dispersos, o que indica uma variância maior nos erros.

Análise Quantitativa

A tabela de métricas quantifica a observação visual:

Modelo	Média dos Erros (Viés)	Desvio Padrão (Variância)
Regressão Linear	0.238348	4.188905
Random Forest	-0.230886	3.753866
SVR	-0.188526	4.103150

- **Viés:** A "Média dos Erros" nos diz se o modelo tende a superestimar ou subestimar as previsões. O **SVR** teve o valor mais próximo de zero (-0.188526), indicando o **menor viés** entre os três.
- **Variância:** O "Desvio Padrão dos Erros" mede a consistência ou dispersão dos erros. O **Random Forest** teve o menor valor (3.753866), indicando a **menor variância**.

Conclusão

Com base na análise, podemos concluir que:

- O modelo com **menor viés** foi o **SVR**.
- O modelo com **menor variância** foi o **Random Forest**.

Embora o SVR tenha um viés ligeiramente menor, a vantagem do Random Forest na consistência de seus erros (menor variância) é mais significativa, tornando seu perfil de erro geral mais robusto e confiável.

6) Verifique a sensibilidade do modelo à remoção de outliers:

- a) Identifique e remova outliers do conjunto de dados usando um método como IQR (Inter quartile range) ou Z-score.

Resultado:

Shape original do DataFrame: (395, 31)

Shape do DataFrame sem outliers: (239, 31)

Número de outliers removidos: 156

- b) Compare o desempenho dos modelos antes e depois da remoção.

Resultado:

--- Tabela Comparativa: Antes vs. Depois da Remoção de Outliers ---

	RMSE Antes	RMSE Depois
Regressão Linear	4.195681	3.407817
Random Forest	3.760959	3.441554
SVR	4.107479	3.673886
Gradient Boosting	3.909271	3.562816

- c) Algum modelo é mais sensível a outliers?

Resultado:

--- Análise de Sensibilidade a Outliers (Ordenado por Melhora) ---

	RMSE Antes	RMSE Depois	Variacao_Percentual
Regressão Linear	4.195681	3.407817	18.777980
SVR	4.107479	3.673886	10.556164
Gradient Boosting	3.909271	3.562816	8.862378
Random Forest	3.760959	3.441554	8.492665

Análise:

Análise de Sensibilidade a Outliers

Foi realizada uma análise para verificar o impacto de dados discrepantes (outliers) na performance dos modelos de regressão, seguindo os passos de identificação, comparação e análise de sensibilidade.

a) Identificação e Remoção de Outliers

Utilizei o método do **Intervalo Interquartil (IQR)** para identificar outliers nas features numéricas do dataset. A aplicação deste método resultou na identificação e remoção de **156 amostras**, reduzindo o conjunto de dados de 395 para 239 pontos.

b) Comparação de Desempenho

Após a remoção dos outliers, todos os modelos foram retreinados no novo dataset "limpo". A tabela abaixo compara o erro (RMSE) de cada modelo antes e depois da remoção:

Modelo	RMSE Antes	RMSE Depois
Regressão Linear	4.1957	3.4078
Random Forest	3.7610	3.4416
SVR	4.1075	3.6739
Gradient Boosting	3.9093	3.5628

Fica evidente que a remoção dos outliers resultou em uma **melhora de performance (redução do RMSE) para todos os modelos**, indicando que os pontos removidos eram, de fato, prejudiciais ao processo de aprendizado.

c) Análise de Sensibilidade

A **Regressão Linear** é o modelo mais sensível a outliers.

A análise da variação percentual na performance comprova essa conclusão:

- **Regressão Linear:** Melhora de **18.78%**
- **SVR:** Melhora de **10.56%**
- **Gradient Boosting:** Melhora de **8.86%**
- **Random Forest:** Melhora de **8.49%**

Justificativa: Este resultado era esperado. Modelos como a **Regressão Linear** e o **SVR** tentam ajustar uma função matemática que passe o mais perto possível de todos os pontos de dados. Por isso, valores extremos (outliers) exercem uma influência desproporcional, "puxando" a linha de regressão ou a fronteira de decisão para longe do padrão geral. Em contrapartida, modelos baseados em árvores como o **Random Forest** são naturalmente mais robustos, pois suas decisões de divisão em "nós" são menos afetadas por alguns poucos valores extremos.

2. Aprendizado supervisionado - Classificação

1) Qual dos seguintes modelos apresenta a melhor performance para um determinada métrica de performance (escolha entre F1-score ou AUC)

a) Random Forest

b) Support Vector Classification

c) XGBoost

Resultado:

--- Avaliando Modelos de Classificação ---

Modelo: Random Forest

F1-Score (weighted): 0.3172

Modelo: SVC

F1-Score (weighted): 0.2895

Modelo: XGBoost

F1-Score (weighted): 0.3021

--- Resultado Final ---

O melhor modelo, com base no F1-Score, foi o 'Random Forest' com um score de 0.3172

Análise:

Comparação de Modelos de Classificação

Para avaliar e comparar os modelos de classificação, foram realizadas as seguintes etapas:

Métrica de Performance: F1-Score

A métrica de performance escolhida foi o **F1-Score (ponderado - weighted)**, porque as classes do dataset são desbalanceadas.

1. **Robustez ao Desbalanceamento:** Em datasets onde algumas classes têm muito mais amostras do que outras, a acurácia pode enganar. O F1-Score, por ser a média entre precisão e recall, oferece uma avaliação mais equilibrada e confiável da performance do modelo em todas as classes.
2. **Visão Completa:** O F1-Score ponderado (average='weighted') calcula a métrica para cada classe e, em seguida, pondera a média pelo número de amostras em cada uma, fornecendo um único número que resume a qualidade geral do classificador.

Comparação de Performance e Conclusão

Os três modelos propostos foram treinados e avaliados, e seus desempenhos foram medidos pelo F1-Score ponderado. Os resultados obtidos foram:

- **Random Forest:** F1-Score = 0.3172
- **SVC:** F1-Score = 0.2895
- **XGBoost:** F1-Score = 0.3021

Com base nesses resultados, o modelo que apresentou a melhor performance para este problema de classificação foi o **Random Forest**, pois obteve o maior F1-Score.

2) Quais são as variáveis (features) mais importantes de acordo com o Random Forest?

Resultado:

--- 15 Variáveis Mais Importantes (Random Forest Classifier) ---

	Feature	Importancia
12	num__absences	0.056907
1	num__Medu	0.042088
11	num__health	0.041574
7	num__freetime	0.041403
10	num__Walc	0.041326
0	num__age	0.039969
8	num__goout	0.039610
6	num__famrel	0.037211
2	num__Fedu	0.035378

	Feature	Importancia
4	num__studytime	0.033800
5	num__failures	0.029192
9	num__Dalc	0.025222
3	num__travelttime	0.023377
36	cat__reason_reputation	0.018624
15	cat__sex_F	0.017600

Análise:

Análise de Importância das Variáveis (Random Forest)

A análise de importância de variáveis do RandomForestClassifier revela quais características dos alunos foram mais decisivas para o modelo ao classificar seu desempenho em faixas de notas (de 'A' a 'F'). A importância é medida pela contribuição de cada feature na redução do erro de classificação ao longo de todas as árvores de decisão do modelo.

Com base nos resultados, as **5 variáveis mais importantes** foram:

1. **Número de faltas escolares** (num__absences)
2. **Nível de educação da mãe** (num__Medu)
3. **Estado de saúde atual** (num__health)
4. **Quantidade de tempo livre** (num__freetime)
5. **Consumo de álcool no fim de semana** (num__Walc)

Conclusão da Análise: O número de faltas (absences) se destaca como o fator mais preditivo. É interessante notar que o modelo utiliza uma combinação de fatores diretamente ligados à vida escolar (absences), ao contexto familiar (Medu) e ao estilo de vida do aluno (health, freetime, Walc) para fazer suas classificações, indicando a complexidade do problema.

3) Identifique qual classe cada modelo tem mais dificuldade de acertar. Existe alguma coisa que pode ser feita para tentar melhorar o classificador nesses casos específicos?

Resultado:

--- Relatório de Performance por Classe ---

--- Modelo: Random Forest ---

	precision	recall	f1-score	support
A	0.00	0.00	0.00	8
B	0.27	0.25	0.26	12
C	0.00	0.00	0.00	12
D	0.32	0.38	0.35	21
F	0.47	0.69	0.56	26

accuracy			0.37	79
macro avg	0.21	0.26	0.23	79
weighted avg	0.28	0.37	0.32	79

=====

--- Modelo: SVC ---

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

A	0.00	0.00	0.00	8
B	0.15	0.17	0.16	12
C	0.00	0.00	0.00	12
D	0.32	0.33	0.33	21
F	0.43	0.73	0.54	26

accuracy			0.35	79
macro avg	0.18	0.25	0.21	79
weighted avg	0.25	0.35	0.29	79

=====

--- Modelo: XGBoost ---

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

A	0.20	0.12	0.15	8
B	0.21	0.25	0.23	12
C	0.09	0.08	0.09	12
D	0.31	0.38	0.34	21
F	0.48	0.42	0.45	26

accuracy			0.30	79
macro avg	0.26	0.25	0.25	79
weighted avg	0.31	0.30	0.30	79

=====

Análise:

Análise de Dificuldade por Classe e Estratégias de Melhoria

A análise detalhada da performance de cada modelo, classe a classe, revela uma dificuldade em classificar as classes minoritárias, um problema comum em cenários com dados desbalanceados.

Dificuldade de Classificação por Modelo

Com base nos F1-Scores por classe, a dificuldade de cada modelo foi:

- **Random Forest e SVC:** Ambos falharam completamente em prever as classes 'A' e 'C', resultando em um F1-Score de 0.00 para ambas. Isso indica que os modelos não conseguiram aprender os padrões dessas classes, provavelmente por falta de exemplos.

- **XGBoost:** Também apresentou extrema dificuldade com as classes minoritárias, sendo a classe '**C**' (F1-Score de 0.09) e a classe '**A**' (F1-Score de 0.15) as mais difíceis de acertar.

Causa do Problema e Estratégias de Melhoria

A causa principal para essa dificuldade é o **desbalanceamento de classes** presente no dataset. Os modelos não possuem exemplos suficientes das classes '**A**' e '**C**' para aprender a distingui-las eficientemente.

Existem estratégias que podem ser aplicadas para melhorar o desempenho nesses casos específicos:


1. **Utilizar Pesos de Classe (class_weight):** Esta é a abordagem mais direta. Ao instanciar os modelos, pode-se usar o parâmetro `class_weight='balanced'`. Isso instrui o algoritmo a dar um peso maior aos erros cometidos nas classes minoritárias durante o treinamento, forçando-o a "prestar mais atenção" nelas.
2. **Técnicas de Reamostragem (Resampling):** O objetivo é balancear artificialmente o conjunto de dados de treino.
 - **Oversampling:** É a técnica mais popular. Ela cria novas amostras sintéticas das classes minoritárias, aumentando sua representatividade no dataset de treino.
 - **Undersampling:** Remove aleatoriamente amostras das classes majoritárias para equilibrar a distribuição. Esta técnica deve ser usada com mais cuidado, pois pode descartar informações úteis.
3. **Coleta de Mais Dados:** No mundo real, a solução ideal seria coletar mais dados, especialmente para as classes sub-representadas ('**A**', '**B**', '**C**'), mas isso nem sempre é possível.
- 4) **Use o shapley additive explanations (SHAP) para identificar o impacto de cada features na classificação gerada por cada um dos algoritmos da questão 1. Interprete o gráfico do SHAP gerado para pelo menos um dos classificadores (<https://shap.readthedocs.io/en/latest/>)**

Resultado:

--- Gerando Análises SHAP para cada Classificador ---

--- Modelo: Random Forest ---

Gráfico de Resumo SHAP para Random Forest:




--- Modelo: SVC ---

100%


79/79 [08:15<00:00, 5.95s/it]

Gráfico de Resumo SHAP para SVC:



--- Modelo: XGBoost ---

Gráfico de Resumo SHAP para XGBoost:



Análise:

Análise de Impacto das Features com SHAP

Para entender como cada modelo utiliza as variáveis para tomar suas decisões, foram gerados gráficos de resumo (summary plots) do SHAP. Estes gráficos mostram o impacto de cada feature na previsão para cada amostra do conjunto de teste. A interpretação detalhada será focada no **Random Forest**, que foi o melhor modelo na avaliação anterior.

Interpretação do Gráfico SHAP (Random Forest)

O gráfico SHAP do Random Forest mostra as seguintes características:

- **Eixo Y (Vertical):** Lista as variáveis ordenadas da mais importante (topo) para a menos importante.
- **Eixo X (Horizontal):** Mostra o impacto médio absoluto das variáveis nas previsões do modelo. Quanto mais à direita, maior a influência.
- **Cores das barras:** Cada cor representa uma classe (A, B, C, D, F), permitindo visualizar quais variáveis influenciam mais fortemente as decisões de cada categoria.

Analisando as principais features do gráfico do Random Forest:

1. **num__failures (Reprovações Anteriores):** É a variável mais impactante. A maior parte de sua influência está associada à classe F, indicando que alunos com mais reprovações anteriores têm alta probabilidade de receber notas baixas. Isso reforça o padrão esperado: histórico ruim é um forte preditor de desempenho futuro.
2. **num__Medu (Escolaridade da Mãe):** Também tem grande impacto, com destaque para a classe B. Isso sugere que uma maior escolaridade da mãe está correlacionada com melhor desempenho acadêmico do aluno.
3. **num__absences (Faltas):** Aparece como uma variável importante, contribuindo para decisões em várias classes. Como esperado, muitas faltas indicam envolvimento reduzido com os estudos, o que impacta negativamente o rendimento.

Comparativo entre Modelos

Embora os modelos utilizem o mesmo conjunto de variáveis, cada um foca em aspectos distintos:

- **Random Forest:** Priorizou o histórico de **reprovações** do aluno (num__failure).
- **XGBoost:** Destacou **escolaridade da mãe** (num__Medu) como a principal variável, mas com maior distribuição de impacto entre várias features.
- **SVC:** Também deu maior importância à **escolaridade da mãe** (num__Medu). Mas percebeu que o gráfico SHAP gerado para o SVC apresentou apenas uma cor (azul), porque foi usada a saída .predict. Para gerar gráficos multiclasse, seria necessário usar .predict_proba, o que exige configurar o modelo SVC com probability=True. No entanto, para este relatório, optei por interpretar em profundidade apenas o modelo Random Forest.

Conclusão

A análise com SHAP revelou de forma clara como as principais variáveis influenciam a classificação dos alunos em diferentes categorias de desempenho. O Random

Forest apresentou uma interpretação coerentes com a realidade estudantil. Fatores como reprovações anteriores, escolaridade da mãe e faltas se destacam como preditores de desempenho. Além disso, a comparação com outros modelos evidenciou como diferentes algoritmos aprendem padrões distintos mesmo utilizando o mesmo conjunto de dados, mas todos convergem ao utilizar uma combinação de fatores para realizar a classificação.

3. Aprendizado não-supervisionado - Clustering

1) Rode os algoritmos de agrupamento k-means, HDBScan (Hierarchical Density-Based Spatial Clustering of Applications with Noise) e GMM (Gaussian Mixture Models).

a) Para os algoritmos que dependem do número de parâmetros k, escolha este parâmetro baseado no valor de silhueta. Reporte os gráficos mostrando o melhor valor de K para cada método.


Resultado – K-means:

--- Calculando Silhouette Score para K-Means ---

Para k=2, o Silhouette Score é 0.0835
Para k=3, o Silhouette Score é 0.0773
Para k=4, o Silhouette Score é 0.0627
Para k=5, o Silhouette Score é 0.0569
Para k=6, o Silhouette Score é 0.0609
Para k=7, o Silhouette Score é 0.0574
Para k=8, o Silhouette Score é 0.0478
Para k=9, o Silhouette Score é 0.0581
Para k=10, o Silhouette Score é 0.0519
Para k=11, o Silhouette Score é 0.0551
Para k=12, o Silhouette Score é 0.0525
Para k=13, o Silhouette Score é 0.0526
Para k=14, o Silhouette Score é 0.0552
Para k=15, o Silhouette Score é 0.0499
Para k=16, o Silhouette Score é 0.0522
Para k=17, o Silhouette Score é 0.0514
Para k=18, o Silhouette Score é 0.0467
Para k=19, o Silhouette Score é 0.0471
Para k=20, o Silhouette Score é 0.0504
Para k=21, o Silhouette Score é 0.0460
Para k=22, o Silhouette Score é 0.0513
Para k=23, o Silhouette Score é 0.0445
Para k=24, o Silhouette Score é 0.0404
Para k=25, o Silhouette Score é 0.0427
Para k=26, o Silhouette Score é 0.0440
Para k=27, o Silhouette Score é 0.0438
Para k=28, o Silhouette Score é 0.0434

Para k=29, o Silhouette Score é 0.0471

Para k=30, o Silhouette Score é 0.0407



O melhor valor de K para o K-Means é 2 com um Silhouette Score de 0.0835

Resultado – GMM:

--- Calculando Silhouette Score para GMM ---

Para k=2, o Silhouette Score é 0.0452

Para k=3, o Silhouette Score é 0.0436

Para k=4, o Silhouette Score é 0.0356

Para k=5, o Silhouette Score é 0.0494

Para k=6, o Silhouette Score é 0.0292

Para k=7, o Silhouette Score é 0.0501

Para k=8, o Silhouette Score é 0.0475

Para k=9, o Silhouette Score é 0.0579

Para k=10, o Silhouette Score é 0.0519

Para k=11, o Silhouette Score é 0.0551

Para k=12, o Silhouette Score é 0.0525

Para k=13, o Silhouette Score é 0.0526

Para k=14, o Silhouette Score é 0.0549

Para k=15, o Silhouette Score é 0.0499

Para k=16, o Silhouette Score é 0.0515

Para k=17, o Silhouette Score é 0.0514


Para k=18, o Silhouette Score é 0.0467

Para k=19, o Silhouette Score é 0.0471

Para k=20, o Silhouette Score é 0.0504

Para k=21, o Silhouette Score é 0.0460

Para k=22, o Silhouette Score é 0.0513
Para k=23, o Silhouette Score é 0.0445
Para k=24, o Silhouette Score é 0.0404
Para k=25, o Silhouette Score é 0.0427
Para k=26, o Silhouette Score é 0.0440
Para k=27, o Silhouette Score é 0.0438
Para k=28, o Silhouette Score é 0.0434
Para k=29, o Silhouette Score é 0.0471
Para k=30, o Silhouette Score é 0.0407



O melhor valor de K para o GMM é 9 com um Silhouette Score de 0.0579

Resultado – HDBSCAN:

O HDBSCAN encontrou 4 clusters.

Número de pontos considerados ruído (outliers): 369

Silhouette Score do HDBSCAN (sem ruído): 0.1376

Análise:

Execução dos Algoritmos de Clustering e Escolha de K

Para esta análise, os algoritmos K-Means, GMM e HDBSCAN foram executados sobre os dados pré-processados. Para os modelos que dependem do parâmetro k (K-Means e GMM), foi realizada uma busca pelo valor ótimo utilizando o **Coeficiente de Silhueta**.

K-Means

O algoritmo foi testado para um número de clusters k variando de 2 a 30. A análise do Coeficiente de Silhueta, conforme visualizado no gráfico, indicou que a melhor performance foi obtida com **k=2**, que alcançou um score de **0.0835**.

Gaussian Mixture Models (GMM)

Seguindo o mesmo processo, o GMM foi avaliado para um número de componentes k de 2 a 30. O valor que maximizou a métrica foi $k=9$, com um Coeficiente de Silhueta de **0.0579**.

HDBSCAN

Este algoritmo descobre o número de clusters automaticamente. Após vários testes com o parâmetro `min_cluster_size`, o valor **4** foi escolhido. Com esta configuração mais sensível, o HDBSCAN conseguiu identificar **4 clusters**, no entanto, classificou a grande maioria dos pontos (369 de 395) como ruído. Ele alcançou um Silhouette Score de **0.1376**.

Conclusão da Análise

Apesar de encontrarmos os valores ótimos de k para K-Means e GMM, os scores de silhueta resultantes são extremamente baixos (muito próximos de 0). Este fato, somado ao resultado do HDBSCAN, que mesmo em uma configuração sensível, considerou a vasta maioria dos dados como ruído, é uma forte evidência de que os dados, em seu formato original de alta dimensão, não possuem uma estrutura de clusters clara e bem definida. Os grupos gerados são de baixa qualidade e com alta sobreposição.

2) Faça uma análise quantitativa dos resultados usando as seguintes métricas:

a) Métricas Internas: Silhouette Score, Davies-Bouldin Index e Calinski-Harabasz Index

b) Métricas Externas: Adjusted Rand Index e Mutual Information Score

Resultado:

--- Tabela de Análise Quantitativa de Clustering ---

	Silhouette	Davies-Bouldin	Calinski-Harabasz	Adj. Rand Index	Mutual Information
Algoritmo					
K-Means (k=2)	0.083465	3.170226	37.127893	0.014575	0.030112
GMM (k=9)	0.057899	2.513128	20.272344	0.012799	0.104032
HDBSCAN	0.137605	1.700181	4.681912	0.081850	0.395593

Análise:

Análise Quantitativa dos Clusters

A análise quantitativa foi realizada para avaliar a qualidade dos agrupamentos gerados pelos algoritmos K-Means, GMM e HDBSCAN nos dados de alta dimensão.

As métricas foram divididas em internas (que avaliam a geometria dos clusters) e externas (que comparam com os rótulos verdadeiros).

- **Silhouette Score:** mede a separação entre os clusters (entre -1 e 1, maior é melhor).
- **Davies-Bouldin Index:** mede a similaridade entre clusters (menor é melhor).
- **Calinski-Harabasz Index:** razão entre dispersão entre clusters e dentro dos clusters (maior é melhor).
- **Adjusted Rand Index:** mede similaridade entre agrupamento e verdade, ajustado por acaso (1 é perfeito, 0 é aleatório).
- **Mutual Information Score:** mede informação mútua entre os clusters e a verdade (não normalizado, maior é melhor).

Análise das Métricas Internas

As métricas que avaliam a qualidade estrutural dos clusters mostraram um resultado misto, mas com o **HDBSCAN se destacando**:

- **Silhouette Score:** O HDBSCAN obteve o maior score (0.137), indicando que seus clusters, embora ainda de baixa qualidade, são geometricamente mais bem definidos que os do K-Means (0.08) e GMM (0.05).
- **Davies-Bouldin Index:** Novamente, o HDBSCAN apresentou o melhor resultado (1.70, o mais baixo), confirmando que seus clusters são mais compactos e separados.
- **Calinski-Harabasz Index:** Scores baixos (37.1, 20.2 e 4.7), onde valores mais altos são melhores, reforçam a conclusão de que a variância entre os clusters é pequena em comparação com a variância dentro deles.

Coletivamente, as métricas internas indicam que os clusters encontrados são de **baixa qualidade**.

Análise das Métricas Externas

As métricas externas, que comparam os clusters encontrados com os rótulos verdadeiros da coluna target, confirmaram a baixa qualidade:

- **Adjusted Rand Index e Mutual Information Score:** Para K-Means e GMM, os valores são extremamente baixos, indicando que seus agrupamentos são praticamente aleatórios em relação às notas reais. O **HDBSCAN**, no entanto, obteve valores maiores (0.08 e 0.39). Ainda está longe de um resultado bom, mas mostra que os 4 clusters encontrados por ele possuem uma correlação fraca, mas real, com as categorias de desempenho dos alunos.

Conclusão

A análise quantitativa nos permite concluir que:

1. **K-Means e GMM** falharam em encontrar uma estrutura de agrupamento significativa, como evidenciado por todas as métricas.
2. O **HDBSCAN**, ao isolar a maioria dos pontos como ruído, conseguiu identificar alguns poucos "núcleos" de dados que possuem uma estrutura relevante.
3. Apesar do sucesso relativo do HDBSCAN, a performance geral ainda é muito baixa, indicando que a dimensionalidade é o principal obstáculo, e que a redução dela é um passo essencial.

3) Plote o agrupamento do melhor método, em sua opinião, em 2D usando dois métodos de redução de dimensionalidade: PCA (Principal Componente Analysis) e UMAP (Uniform Manifold Approximation and Projection for Dimension Reduction). Reporte a variância/qualidade da representação capturada por cada método.

Resultado:


--- Qualidade da Representação e dos Clusters ---

PCA: A variância explicada pelos 2 componentes é de 25.62%

Silhouette Score dos clusters no espaço PCA: 0.3785

Silhouette Score dos clusters no espaço UMAP: 0.3518

Comparação de Clustering em Espaços Reduzidos



Análise:

Análise dos Clusters em 2D Após Redução de Dimensionalidade

Para visualizar os agrupamentos, os dados foram projetados em um espaço 2D utilizando as técnicas de PCA e UMAP. O algoritmo K-Means (com k=2) foi escolhido e aplicado a essas novas representações, porque, após alguns testes, foi o que gerou gráficos com melhor visualização.

Análise da Representação com PCA

- **Qualidade da Representação:** A projeção 2D do PCA capturou **25.62%** da variância total dos dados originais. Este é um valor relativamente baixo, indicando que a estrutura dos dados é complexa e não pode ser facilmente resumida por dois eixos lineares.

- **Qualidade do Clustering:** A aplicação do K-Means neste espaço PCA resultou em um Coeficiente de Silhueta de **0.3785**. Este valor é muito superior ao valor obtido nos dados originais (~0.08).

Análise da Representação com UMAP

- **Qualidade da Representação:** A qualidade do UMAP é avaliada de forma qualitativa pela sua capacidade de separar os dados. Ela não fornece uma variância como o PCA para fazer essa análise.
- **Qualidade do Clustering:** Neste espaço, o K-Means alcançou um Coeficiente de Silhueta de **0.3518**, o que também representa uma melhora em relação aos dados originais.

4) Faça uma análise dos resultados da melhor técnica de dimensionalidade, em sua opinião, baseado nas variáveis originais (antes da redução).

Resultado:

--- Análise de Variáveis Numéricas (Médias por Cluster) ---

cluster_encontrado	0	1
age	16.839450	16.519774
Medu	2.064220	3.593220
Fedu	1.944954	3.231638
traveltime	1.555046	1.316384
studytime	2.119266	1.932203
failures	0.472477	0.163842
famrel	3.986239	3.892655
freetime	3.188073	3.293785
goout	2.995413	3.248588
Dalc	1.256881	1.757062
Walc	2.059633	2.576271
health	3.536697	3.576271
absences	4.770642	6.864407

--- Análise de Variáveis Categóricas (Distribuição por Cluster) ---

----- Análise da Categoria: school -----

school	GP	MS
cluster_encontrado		
0	0.853211	0.146789
1	0.920904	0.079096

----- Análise da Categoria: sex -----

sex	F	M
cluster_encontrado		
0	0.62844	0.37156
1	0.40113	0.59887

----- Análise da Categoria: address -----

address	R	U
cluster_encontrado		
0	0.266055	0.733945
1	0.169492	0.830508

----- Análise da Categoria: famsize -----

famsize	GT3	LE3
cluster_encontrado		
0	0.715596	0.284404
1	0.706215	0.293785

----- Análise da Categoria: Pstatus -----

Pstatus	A	T
cluster_encontrado		
0	0.064220	0.935780
1	0.152542	0.847458

----- Análise da Categoria: Mjob -----

Mjob	at_home	health	other	services	teacher
cluster_encontrado					
0	0.229358	0.027523	0.477064	0.252294	0.013761
1	0.050847	0.158192	0.209040	0.271186	0.310734

----- Análise da Categoria: Fjob -----

Fjob	at_home	health	other	services	teacher
cluster_encontrado					
0	0.064220	0.022936	0.623853	0.270642	0.018349
1	0.033898	0.073446	0.457627	0.293785	0.141243

----- Análise da Categoria: reason -----

reason	course	home	other	reputation
cluster_encontrado				
0	0.385321	0.261468	0.073394	0.279817
1	0.344633	0.293785	0.112994	0.248588

----- Análise da Categoria: guardian -----

guardian	father	mother	other
cluster_encontrado			
0	0.243119	0.637615	0.119266
1	0.209040	0.757062	0.033898

----- Análise da Categoria: schoolsup -----

schoolsup	no	yes
cluster_encontrado		
0	0.871560	0.128440
1	0.870056	0.129944

----- Análise da Categoria: famsup -----

famsup	no	yes
cluster_encontrado		
0	0.444954	0.555046
1	0.316384	0.683616

----- Análise da Categoria: paid -----

paid	no	yes
cluster_encontrado		
0	0.605505	0.394495
1	0.463277	0.536723

----- Análise da Categoria: activities -----

activities	no	yes
cluster_encontrado		
0	0.555046	0.444954

1	0.412429	0.587571
---	----------	----------

----- Análise da Categoria: nursery -----

nursery	no	yes
cluster_encontrado		
0	0.247706	0.752294

1	0.152542	0.847458
---	----------	----------

----- Análise da Categoria: higher -----

higher	no	yes
cluster_encontrado		
0	0.073394	0.926606

1	0.022599	0.977401
---	----------	----------

----- Análise da Categoria: internet -----

internet	no	yes
cluster_encontrado		
0	0.238532	0.761468

1	0.079096	0.920904
---	----------	----------

----- Análise da Categoria: romantic -----

romantic	no	yes
cluster_encontrado		
0	0.669725	0.330275

1	0.661017	0.338983
---	----------	----------

Análise:

Análise de Perfil dos Clusters

A análise foi realizada sobre os clusters encontrados pela abordagem UMAP + K-Means. Ao avaliar as características originais dos membros de cada grupo, foi possível traçar um perfil distinto para cada um, revelando uma divisão de histórico acadêmico.

Perfil do Cluster 1:

Este grupo é caracterizado por um ambiente familiar com maior escolaridade.

- **Educação dos Pais:** As médias de educação da mãe (Medu: 3.59) e do pai (Fedu: 3.23) são mais altas que no outro grupo.
- **Apoio Educacional:** Recebem mais apoio familiar (famsup) e têm mais acesso a aulas pagas (paid).
- **Histórico Acadêmico:** Apresentam um número muito baixo de reprovações anteriores (failures).

Perfil do Cluster 0:

Este grupo, agrupa alunos com um perfil de maior dificuldade acadêmica e menor suporte familiar educacional.

- **Histórico Acadêmico:** A característica mais marcante é o número quase três vezes maior de reprovações anteriores (failures: 0.47 vs 0.16).
- **Educação dos Pais:** Os pais possuem, em média, um nível de escolaridade mais baixo.
- **Perfil Demográfico:** Este grupo possui uma proporção maior de alunas do sexo feminino (63%).

Conclusão

Clustering conseguiu identificar e separar de forma coerente dois grupos de alunos com perfis socioeconômicos e de histórico acadêmico distintos, revelando uma estrutura relevante e interpretável nos dados.

5) Reporte qual dos métodos você usaria para resolver o problema e por quê.

Método Escolhido e Justificativa

Dentre os métodos testados — K-Means, Gaussian Mixture Models (GMM) e HDBSCAN — o **HDBSCAN** foi o que apresentou as melhores métricas, considerando a natureza dos dados. Portanto, seria o escolhido.

Justificativas:

- **Métricas internas (3.2):** O HDBSCAN obteve o maior **Silhouette Score** (0.1376) e o menor **Davies-Bouldin Index** (1.70), indicando que seus clusters são mais coesos e bem separados do que os gerados pelos outros métodos. Apesar de um **Calinski-Harabasz Index** mais baixo, a qualidade geométrica dos grupos foi superior.
- **Métricas externas (3.2):** Também apresentou os maiores valores em **Adjusted Rand Index** (0.0818) e **Mutual Information** (0.3955), o que indica que seus agrupamentos, embora não perfeitos, **capturam parcialmente a estrutura presente nos rótulos reais** dos alunos (notas).

Apesar do HDBSCAN ser o escolhido, para as análises anteriores utilizei o k-means porque preferi os gráficos gerados por ele para visualização.