Predição de Propriedades Ópticas de Estruturas Plasmônicas Usando Redes Neurais Profundas

Vinicius Trindade, Guilherme Guerra, Fabiano Santana
Departamento de Ciência da Computação, UFMG
Belo Horizonte, Brasil
Email: vinicius.trindade@dcc.ufmg.br, guilhermeguerra@dcc.ufmg.br, fabiano@dcc.ufmg.br

***Abstract*—O projeto de estruturas plasmônicas depende tradicionalmente de simulações numéricas que são computacionalmente custosas. Recentemente, o Aprendizado Profundo (DL) surgiu como uma alternativa para acelerar esse processo. Este trabalho explora a aplicação de uma arquitetura de rede neural híbrida, combinando Redes Neurais Convolucionais (CNNs) e Redes Neurais Recorrentes (RNNs), para prever os espectros de absorção de nanoestruturas plasmônicas diretamente a partir de suas geometrias 2D. Enquanto estudos anteriores utilizaram conjuntos de dados muito grandes, este estudo investiga a viabilidade desta abordagem em um dataset pequeno. A solução utiliza um arquitetura reduzida, otimizada para evitar overfitting. Os resultados demonstram que o modelo foi capaz de aprender características marcantes das curvas de absorção.**

***Index Terms*—Aprendizado Profundo, Plasmônica, Nanofotônica**

I. Introdução

UMA importante etapa de qualquer trabalho relacionado à nano dispositivos consiste em utilizar um software de simulação para variar parâmetros e obter as condições que tornam o dispositivo ótimo para alguma função. Esta etapa também permite a predição de falhas e diminui os custos da etapa de produção, uma vez que restringe o número de dispositivos que possivelmente funcionarão corretamente. Ao se tratar de dispositivos fotônicos, há dois softwares amplamente utlizados para simulação: Ansys Lumerical e COMSOL Multiphysics. Ambos os softwares utilizam o método de simulação por elemento finito para resolver geometrias e avaliar propriedades definidas pelo usuário, sendo possível criar ambientes com evolução temporal e avaliar mais de uma propriedade simultaneamente. Durante a execução da simulação, esses softwares resolvem equações diferenciais complexas, necessitando de computadores com grande capacidade de processamento para funcionarem em um tempo viável.

Nesse contexto, existem muitos projetos em que o ambiente de simulação é refinado para um mesmo conjunto finito de variáveis de entrada e um mesmo conjunto finito de parâmetros avaliados na saída. Assim, com os recentes avanços em Machine Learning e I.A., é possível pensar na substituição dos softwares por uma rede neural que lide apenas com as entradas e saídas da simulação, aprendendo sobre a correlação entre ambas para fazer predição de um dado de entrada não testado. Essa substituição dos softwares de simulação por redes neurais reduz o tempo para obtenção das respostas, bem como permite um número maior de variáveis teste, uma vez que os modelos utilizados possuem arquiteturas pensadas para grandes volumes de dados.

Um dos problemas comuns no contexto de simulação em dispositivos fotônicos é a obtenção do espectro de resposta de nanoestruturas. Ao incidir luz de um ou vários comprimentos de onda definidos, se quer obter quais serão os valores de campo absorvido, transmitido ou refletido pelo componente (de dimensão nanométrica) em questão. Este trabalho foca em dispositivos formados por nanoestruturas de ouro que são projetados para amplificar o campo elétricos próximo para determinados valores de comprimento de onda. Esses dispositivos são comumente utilizados como sensores para a técnica de SERS (Surface Enhanced Raman Spectroscopy), onde, ao amplificar o campo elétrico próximo nas nanoestruturas, aumenta-se também o sinal Raman do analito depositado sobre as mesmas. Dessa forma, o princípio de otimização deste dispositivo consiste em fazer com que a matriz de nanoestruturas promova o maior aumento possível do campo próximo, se valendo de variação da forma geométrica, do tamanho e da disposição espacial.

Usualmente, desenvolve-se um ambiente de simulação em um dos softwares citados para variar os parâmetros mencionados acima e avaliar qual o maior aumento de campo possível. Neste trabalho, propõe-se treinar uma rede neural com os dados de um conjunto de simulações feitas no COMSOL para dispositivos SERS e, com isso, permitir a substituição do ambiente de simulação pela predição fornecida pela rede neural. O modelo desenvolvido é composto por uma rede neural convolucional (CNN), amplamente utilizada para análise de imagens, e por uma rede neural recorrente (RNN), que funciona bem para predição de séries. Diferentemente de outros trabalhos da literatura, este artigo utiliza um dataset pequeno, com menos de 100 simulações. Dessa forma, o objetivo deixa de ser obter uma precisão perfeita da curva de absorção para então buscar encontrar as principais características que definem o espectro.

Este artigo procede como segue. A Seção II apresenta os trabalhos relacionados à predição de propriedades de materiais utilizando redes neurais. A Seção III descreve o método proposto. A Seção IV discute a avaliação e os experimentos realizados. Por fim, a Seção V reúne as conclusões e considerações finais deste trabalho.

II. Trabalhos Relacionados

A aplicação de aprendizado profundo na nanofotônica tem crescido rapidamente, abordando tanto a modelagem direta, ou seja, a previsão da resposta óptica a partir da geometria, como também o design inverso, ou seja, a descoberta da geometria a partir da resposta óptica [1]. Trabalhos iniciais utilizavam redes neurais totalmente conectadas (FCNNs) para aproximar as equações de Maxwell, entretanto, estas enfrentavam dificuldades com entradas complexas e de alta dimensão.

Para lidar com a complexidade espacial, as Redes Neurais Convolucionais (CNNs) tornaram-se o padrão para a extração de características geométricas de nanoestruturas e imagens. Liu et al. [3] e Peurifoy et al. [1] demonstraram que as CNNs poderiam mapear efetivamente propriedades estruturais para espectros ópticos. No entanto, espectros ópticos são dados inerentemente sequenciais, onde a correlação entre pontos de frequência adjacentes é relevante, aspecto que não é o foco das CNNs.

Abordando essa questão, Sajedian et al. [2] propuseram uma arquitetura híbrida, combinando CNNs para extração de características de imagens e Redes Neurais Recorrentes (RNNs) para lidar com os pontos sequenciais para previsão espectral. O modelo, treinado com dados de 100.000 simulações, alcançou alta precisão ao capturar tanto as características espaciais, via CNN, quanto as dependências espectrais, via RNN. Eles demonstraram que essa abordagem poderia prever curvas de absorção em milissegundos, substituindo simulações demoradas e softwares caros.

Apesar desses avanços, a maioria dos modelos atuais da literatura depende de grandes conjuntos de dados que requerem recursos computacionais consideráveis para serem gerados. Este trabalho diferencia-se ao investigar a eficácia da arquitetura CNN-RNN com um dataset pequeno, mais fácil de ser gerado. Ao contrário de Sajedian et al., que utilizaram redes neurais profundas muito extensas, uma arquitetura compacta e reduzida foi utilizada neste artigo, otimizada para aprender com menos de 100 amostras, evitando overfitting e tornando o aprendizado profundo acessível para pesquisas com poucos dados.

III. Metodologia

Como já mencionado, o objetivo deste trabalho foi desenvolver uma rede neural para prever as respostas ópticas de estruturas plasmônicas. Assim, esta seção descreve a metodologia seguida, que pode ser dividida em duas etapas. Primeiramente, o conjunto de dados para treino e teste do modelo foi gerado no software de simulação COMSOL. Esse dataset consiste de imagens 2D de nanoestruturas e seus respectivos espectros de absorção, e está melhor descrito na Subseção III-A. A outra etapa consiste no desenvolvimento da rede neural em si, que foi otimizada para funcionar bem com um dataset pequeno. Este processo é abordado na Subseção III-B.

A. Dados

Para gerar os dados a serem utilizados neste projeto, o software COMSOL foi utilizado. Este software realiza simulações por métodos numéricos e permitiu a obtenção dos espectros ópticos das estruturas plasmônicas selecionadas. No total, 72 estruturas foram simuladas, quantidade pequena comparada ao tamanho normal de datasets para treinamento de redes neurais. As estruturas utilizadas foram criadas de forma aleatória, respeitando alguns limites de viabilidade. Todas elas possuem uma altura fixa de 50nm, o que permitiu retirar a altura como parâmetro do modelo e utilizar apenas imagens 2D como entrada. Além disso, foram consideradas apenas estruturas de ouro e vidro, viabilizando a utilização de imagens em preto e branco que, por não necessitarem da escala RGB, são 3 vezes mais compactas que imagens coloridas.

Como as estruturas analisadas são cristais, ou seja, materiais periódicos, basta analisar apenas a estrutura que se repete para obter as propriedades do material como um todo. Isso permite que a entrada do modelo sejam apenas imagens das estruturas que se repetem e formam o material. Como já mencionado, como foram utilizados apenas ouro e vidro, as imagens podem ser em preto e branco, e como todas as estruturas tem a mesma altura, pode-se utilizar imagens 2D. Todas as imagens possuem 100x100 pixels, dimensão que se mostrou apropriada para obter um balanço satisfatório entre qualidade do modelo e necessidade de poder computacional. A seguir, a Figura 1 e a Figura 2 mostram dois exemplos de imagens utilizadas, que estão coloridas apenas para facilitar a visualização.



Fig. 1. Exemplo de imagem de input.



Fig. 2. Exemplo de imagem de input.

O output do modelo deve ser o espectro de absorção da estrutura. Assim, para cada estrutura simulada no COMSOL, obteve-se o espectro associado. Foi definido que cada curva de espectro deveria ser representada através de 100 pontos. O valor referente ao eixo x representa o comprimento de onda, enquanto que o valor no eixo y representa a intensidade da onda daquele comprimento. Como esses valores são muito pequenos, na ordem de e^{-14}, optou-se por normalizar esses valores, e assim evitar que o modelo trabalhasse com valores muito pequenos. A seguir, a Figura 3 e a Figura 4 mostram dois exemplos de espectros de absorção.

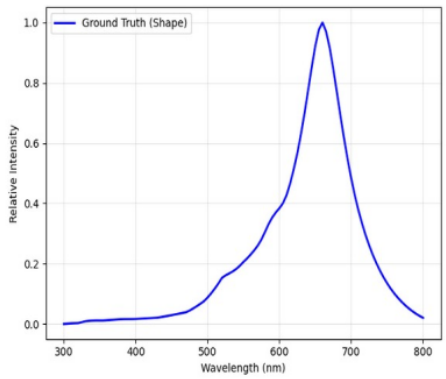


Fig. 3. Exemplo de espectro de absorção.

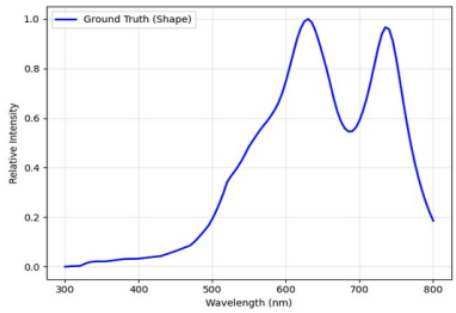


Fig. 4. Exemplo de espectro de absorção.

B. Rede Neural

A arquitetura proposta neste trabalho é um modelo híbrido que combina Redes Neurais Convolucionais (CNN) e Redes Neurais Recorrentes (RNN), especificamente a Gated Recurrent Unit (GRU). A escolha dessa topologia se deve a natureza do problema: a entrada é uma imagem 2D (geometrial espacial), enquanto a saída é um espectro contínuo (sequência de valores).

Diferentemente da abordagem de referência que utilizou redes profundas com 42 camadas para o grande volume de dados, este trabalho propõe uma arquitetura compacta, otimizada para generalizar bem conjuntos reduzidos de dados e evitar overfitting.

1) Arquitetura: O modelo, denominado CNN-GRU Reduced, é composto por três estágios principais (representados na Fig. 5):

- **Extração de Características (CNN):** A entrada da rede consiste em imagens em preto e branco de dimensão 100 × 100 pixels. A rede possui três blocos convolucionais sequenciais. O primeiro bloco utiliza 32 filtros seguido por blocos de 64 e 128 filtros, respectivamente. Cada bloco é composto por uma camada de convolução (kernel 3 × 3), normalizada em lote (Batch Normalization) e função de ativação LeakyReLU(inclinação negativa de 0,1). Camadas de Max Pooling são aplicadas para reduzir a dimensionalidade espacial das características.
- **Processamento Sequencial (GRU):** Após as camadas convolucionais, os mapas de características resultantes são redimensionados para uma estrutura sequencial, onde a dimensão da largura da imagem é tratada como o passo de tempo (time step). Essa sequência alimenta uma camada GRU com 256 unidades ocultas. A GRU é escolhida em detrimento da LSTM (Long Short-Term Memory) por possuir menos parâmetros, sendo mais adequada para cenários com poucos dados, mantendo a capacidade de aprender dependências não-lineares entre os comprimentos de onda do espectro.
- **Regressão (MLP):** A saída da GRU é processada por camadas totalmente conectadas, que projetam o vetor de características para a dimensão final do espectro de saída (101 pontos de comprimento de onda).

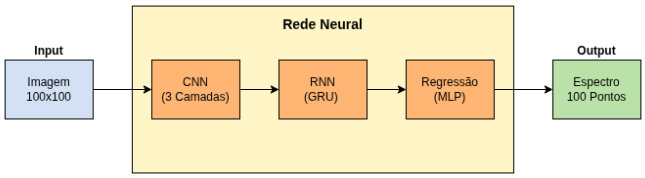


Fig. 5. Arquitetura geral da rede neural.

2) Treinamento: O treinamento foi realizado supervisionado, utilizando Erro Quadrático Médio (MSE - Mean Squared Error) como função de perda, dado que o objetivo é a regressão precisa dos valores de campo elétrico.

Para a otimização, utilizamos o algoritmo NAdam (Nesterov-accelerated Adam), que combina as vantagens do Adam com o momento de Nesterov, convergindo mais rápido. Os dados de saída (espectros) foram normalizados utilizando StandardScaler para garantir média zero e desvio padrão unitário, facilitando a estabilidade numérica durante o treinamento.

O processo de aprendizagem foi configurado para um máximo de 500 épocas. No entanto, para mitigar o risco de overfitting e otimizar o tempo computacional, implementamos a técnica de parada antecipada (Early Stopping). Nessa técnica, o treinamento é interrompido automaticamente caso a perda no conjunto de validação não apresente melhoria por 50 épocas consecutivas, garantindo que o modelo preserve a melhor capacidade de generalização alcançada antes de começar a memorizar os dados de treino.

Devido à escassez de dados, o conjunto de dados foi dividido na proporção de 80% para treinamento, 10% para validação e 10% para teste. Essa divisão prioriza o volume de dados disponível para o aprendizado dos pesos, deixando uma parcela mínima, porém representativa, para a avaliação de generalização.

IV. Resultados

Nesta seção, apresentamos a avaliação do desempenho da rede neural proposta, analisando tanto a convergência durante o treinamento quanto a fidelidade das curvas espectrais preditas em comparação com as simulações numéricas.

A. Convergência do Treinamento

A estabilidade do processo de aprendizado pode ser observada na Fig. 6, que apresenta o histórico da função de perda (MSE) para os conjuntos de treinamento, validação e teste ao longo das épocas.

Observa-se um decaimento consistente da perda de treinamento, indicando que a rede foi capaz de aprender as características geométricas das nanoestruturas. As curvas de validação e teste acompanham a tendência de queda e estabilizam em um patamar próximo, o que demonstra que o modelo possui boa capacidade de generalização e não sofreu overfitting severo, validando a eficácia da estratégia de Early Stopping e da arquitetura reduzida proposta.

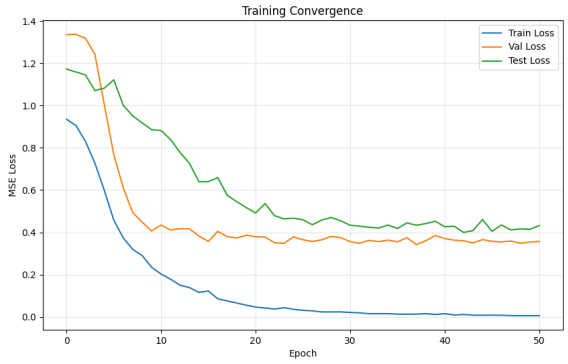


Fig. 6. Histórico de convergência do treinamento. As curvas indicam a redução do Erro Quadrático Médio (MSE) para os conjuntos de treino, validação e teste, demonstrando a estabilidade do aprendizado.

B. Predição Espectral

Para avaliar a qualidade das predições, o modelo treinado foi aplicado a geometrias do conjunto de teste que não foram vistas durante o treinamento. As Figuras 7, 8, 9 e 10 ilustram comparações diretas entre o espectro simulado pelo COMSOL (linha azul) e o espectro predito pela rede neural (linha laranja).

1) Análise de Ressonância: Um dos resultados mais importantes é a capacidade do modelo de identificar corretamente a posição dos picos de ressonância plasmônica no espectro. Como observado na Fig. 7 (referente à amostra *Imagem_09_4*), na Fig. 8 (referente à amostra *Imagem_02_1*) e na Fig. 9 (referente à amostra *Imagem_04_5*), a rede neural conseguiu capturar com precisão o comprimento de onda (λ) onde ocorre a máxima absorção/campo elétrico. Para aplicações de sensoriamento (SERS), a localização correta desse pico é mais crítica do que sua magnitude absoluta.

2) Limitações e Casos de Falha: Apesar do bom desempenho geral, existem casos onde o modelo apresenta divergências significativas, como ilustrado na Fig. 10 (amostra *Imagem_07_1*). Diferentemente dos casos anteriores, aqui o modelo superestimou consideravelmente a amplitude do campo elétrico e previu um pico de ressonância intenso na região de 750-800 nm que não existe na simulação original.

Essa discrepância evidencia as limitações impostas pelo tamanho reduzido do conjunto de dados. É provável que

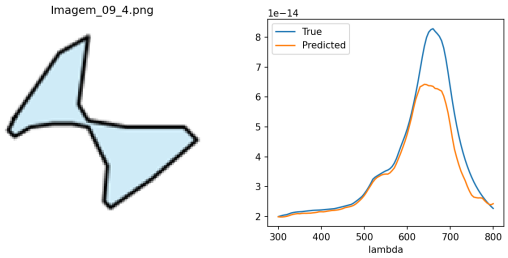


Fig. 7. Comparação entre espectro simulado e predito para uma geometria complexa. O modelo captura com precisão a posição do pico principal de ressonância em torno de 650nm.

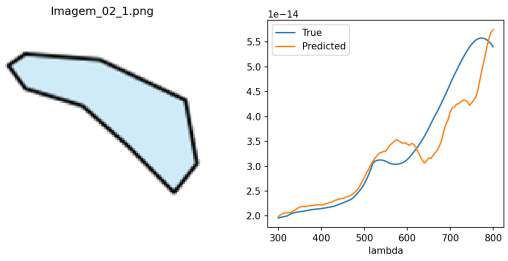


Fig. 8. Predição para uma geometria com variação espectral suave. A rede neural reproduz fielmente a tendência de crescimento do campo elétrico.

esta geometria específica possua características que são subrepresentadas no conjunto de treinamento. Sem exemplos suficientes de estruturas similares, a rede neural pode associar incorretamente essas geometrias a comportamentos espectrais de outras classes de estruturas que possuem alta absorção no infravermelho, resultando em uma predição incorreta para este caso. Este resultado reforça a necessidade futura de expandir o dataset para cobrir melhor o espaço de variações geométricas possíveis.

V. Conclusão

Este trabalho apresentou uma abordagem baseada em Deep Learning para acelerar a predição de propriedades ópticas de nanoestruturas plasmônicas, visando substituir ou complementar simulações de alto custo. A arquitetura proposta, CNN-GRU Reduced, foi projetada especificamente para lidar com a escassez de dados, um cenário comum em pesquisas experimentais onde a geração de grandes volumes de simulações é inviável.

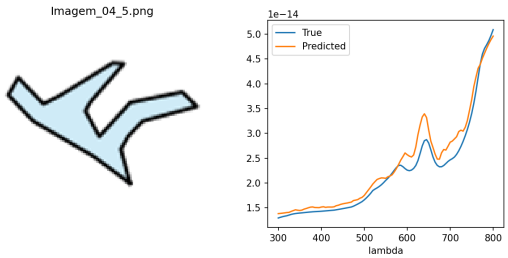


Fig. 9. Predição em geometria ramificada. O modelo demonstra robustez ao identificar corretamente a presença e a posição de múltiplos picos locais de ressonância ao longo do espectro.

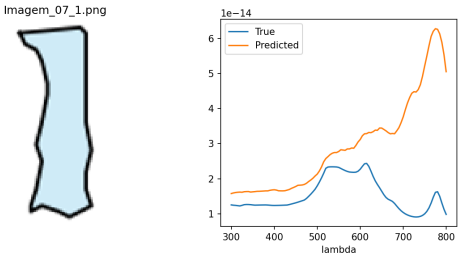


Fig. 10. Exemplo de divergência na predição. O modelo superestimou a amplitude na região do infravermelho, indicando uma ”alucinação” de ressonância possivelmente causada pela escassez de exemplos similares no conjunto de treinamento.

Os resultados obtidos demonstram que o modelo híbrido é capaz de extrair eficientemente as características espaciais das geometrias 2D e mapeá-las para a resposta espectral correspondente. O modelo obteve êxito na identificação da posição dos picos de ressonância plasmônica, parâmetro crítico para a eficiência de dispositivos baseados em SERS. A estratégia de treinamento, combinando o otimizador NAdam com a técnica de Early Stopping, foi eficaz para garantir a convergência e mitigar o overfitting em um conjunto de poucos dados.

Entretanto, a análise dos casos de falha revelou limitações intrínsecas ao tamanho reduzido do dataset. Para geometrias com características pouco representadas no treinamento, o modelo tende a apresentar divergências na amplitude do campo elétrico, chegando a alucinar picos de ressonância em regiões do espectro onde não deveriam existir. Isso confirma que, embora a arquitetura seja robusta, a capacidade de generalização para todo o espaço de design geométrico é limitada pela diversidade dos dados de entrada.

Como trabalhos futuros, a prioridade imediata é a expansão do conjunto de dados. Dado que técnicas tradicionais de Data Augmentation (como rotação) não são aplicáveis devido à natureza vetorial da interação luz-matéria, portanto, é necessária a geração de novas simulações cobrindo uma variabilidade maior de formas e ângulos.

Por fim, o sucesso do modelo preditivo abre caminho para a implementação de algoritmos de design inverso, permitindo a descoberta automática de geometrias otimizadas para aplicações nanofotônicas específicas.

REFERENCES

[1] J. Peurifoy et al., ”Nanophotonic particle simulation and inverse design using artificial neural networks,” *Science Advances*, vol. 4, no. 6, 2018.

[2] I. Sajedian, J. Kim, and J. Rho, ”Finding the optical properties of plasmonic structures by image processing using a combination of convolutional neural networks and recurrent neural networks,” *Microsystems & Nanoengineering*, vol. 5, no. 27, 2019. [Online]. Available: https://doi.org/10.1038/s41378-019-0069-y

[3] D. Liu et al., ”Training deep neural networks for the inverse design of nanophotonic structures,” *ACS Photonics*, vol. 5, no. 4, pp. 1365–1369, 2018.